

Project Task Week 1 : *Data Ingestion Pipeline* (Pembersihan Log Transaksi) & Indikator Penilaian

Objek : Data log transaksi harian klien *E-Commerce* berupa file *transaction_log.json*

Platform : Google Colaboratory atau Python Notebook Alternatif.

Aturan : Pengerjaan **wajib** menggunakan fitur bawaan (*built-in*) Python (List, Tuple, Dictionary, Set, Loop, If-Else, Fungsi). Dilarang keras menggunakan *library* eksternal seperti Pandas atau NumPy.

Konteks : Tim *Data Engineering* PT VINIX SEVEN AURUM saat ini sedang membangun fondasi *machine learning pipeline* untuk salah satu klien E-Commerce. Klien mengirimkan *dump data* transaksi harian, namun karena ada *bug* di sistem mereka, data tersebut banyak mengandung anomali (harga negatif, *null*, kategori teks tidak seragam, dan duplikasi ID pelanggan). Karena itu, tugas ini tidak hanya menguji kemampuan menulis kode, tetapi juga kemampuan menyaring dan memanipulasi data mentah agar siap digunakan untuk analitik lanjutan.

Soal/Instruksi

No.	Soal/Instruksi	Output yang diharapkan
1	Pembersihan Data Dasar (Looping & Control Flow) Gunakan import json dan open() untuk membaca file JSON yang sudah diunggah. Buatlah logika iterasi untuk membaca seluruh baris transaksi. Lakukan <i>filtering</i> dengan menyingkirkan data jika harga (price) bernilai negatif atau <i>null</i>, serta jika nama produk kosong. Seragamkan format semua teks kategori produk menjadi huruf kecil (<i>lowercase</i>) tanpa spasi berlebih.	Sebuah list baru bernama <i>cleaned_data</i> yang hanya berisi <i>dictionary</i> data valid dengan format kategori teks yang seragam.

No.	Soal/Instruksi	Output yang diharapkan
2	Ekstraksi Pelanggan Unik (Data Structure: Set) Dari data yang sudah dibersihkan pada Soal 1, manajer proyek Vinix7 membutuhkan daftar pelanggan yang bertransaksi hari ini tanpa duplikasi. Ekstrak data tersebut.	Sebuah tipe data set bernama <code>unique_customers</code> berisi ID pelanggan, dan kode untuk mencetak total jumlahnya ke layar bawah (<i>output cell</i>).
3	Agregasi Pendapatan (Data Structure: Dictionary) Gunakan logika <i>looping</i> pada <code>cleaned_data</code> untuk menghitung total akumulasi pendapatan (<i>revenue</i>) untuk masing-masing kategori produk.	Sebuah dictionary bernama <code>revenue_per_category</code> dengan <i>key</i> berupa nama kategori dan <i>value</i> berupa total pendapatan.
4	Praktik Modularitas dalam Notebook (Functions) Meskipun berada dalam satu <i>notebook</i>, biasakan menulis kode secara modular. Kelompokkan logika Soal 1, 2, dan 3 ke dalam fungsi-fungsi (<i>def</i>) tersendiri di satu Code Cell (Sel Kode) khusus "Fungsi/Utils". Kemudian, panggil fungsi-fungsi tersebut secara berurutan di Code Cell terpisah (sebagai "Main Execution") untuk menampilkan laporan akhirnya.	Pemisahan yang jelas antara Cell yang berisi definisi fungsi (<i>def</i>) dan Cell yang berisi eksekusi fungsi serta <i>print output</i> .

Format pengumpulan: PDF.

- Kelompok/Identitas.
- Link URL Google Colab.
- Setiap Instruksi wajib menyertakan potongan kode (*screenshoot*), output beserta penjelasannya.

Indikator Penilaian

Indikator Penilaian	Bobot	Kriteria penilaian (ringkas)
1. Penggunaan Struktur Data Python	25%	Ketepatan penggunaan list (untuk menyimpan sekumpulan transaksi), set (untuk ID unik), dan dictionary (untuk agregasi per kategori).
2. Logika Pembersihan & Perhitungan	25%	Logika iterasi berjalan tanpa <i>error</i> , mem-filter anomali (<i>None</i> / harga negatif) dengan tepat, manipulasi string (<i>lowercase/strip</i>) berfungsi, dan agregasi <i>revenue</i> akurat.
3. Modularitas Program (Cell Structuring)	20%	Mampu membungkus logika ke dalam fungsi (<i>def</i>) di satu <i>Cell</i> awal, dan melakukan pemanggilan eksekusi (<i>workflow</i>) di <i>Cell</i> berikutnya secara rapi.
4. Struktur Penyajian & Kerapian Kode	15%	Penamaan variabel logis/profesional, indentasi rapi, memanfaatkan <i>Text Cell</i> (Markdown) untuk memberi judul bagian, dan dokumentasi (<i>comments</i>) jelas.
5. Penyelesaian Skenario Bisnis	15%	Output akhir memenuhi ekspektasi kebutuhan klien Vinix7 (jumlah unik pelanggan benar, total pendapatan per kategori tepat, data kotor terbuang).