

Tugas Minggu 3 – Divisi Data Analyst

TO: ML Team, Vinix7

FROM: Head of Data Analytics, Vinix7

SUBJECT: Data Preprocessing & Pipeline Engineering for Predictive Analytics

1. Latar Belakang Proyek

Vinix7 telah ditunjuk oleh klien untuk membangun model **Machine Learning** yang dapat memprediksi performa dan tingkat retensi karyawan mereka. Sebagai tahap inisiasi, pihak klien menyerahkan data historis karyawan.

Berdasarkan hasil profiling awal dari tim data kita, data klien ini sangat jauh dari standar kesiapan *Machine Learning*. Terdapat nilai yang hilang, tipe data yang tercemar, dan struktur fitur yang menyalahi aturan **1 feature = 1 dimension**. Jika data mentah ini langsung disuapkan ke algoritma ML, sistem dipastikan akan mengalami *crash* atau menghasilkan model yang sangat bias (*Garbage In, Garbage Out*).

2. Objektif Tugas (*Business Requirements*)

Tugas Anda minggu ini bukan untuk melatih algoritma ML, melainkan membangun Pabrik Pemrosesan Data (*Data Normalization Pipeline*). Anda harus merancang alur yang dapat membersihkan kotoran dan mengubah data mentah klien menjadi matriks angka secara otomatis, dengan spesifikasi teknis berikut.

A. String Preprocessing & Feature Extraction

- Identifikasi dan selesaikan anomali tekstual, termasuk fitur yang menyimpan data gabungan serta fitur numerik yang terganggu teks asing/symbol .
- **Expected Output:** Entitas gabungan terekstrak menjadi fitur terpisah, tipe data murni, dan penulisan kategori terstandarisasi.

B. Missing Value Imputation

- Identifikasi fitur dengan ruang data kosong (NaN).
- Terapkan strategi imputasi statistik untuk fitur numerik maupun kategorikal.
- **Expected Output:** Tidak ada data bernilai Null yang akan lolos ke tahap modelling.

C. Feature Encoding

- Terjemahkan seluruh fitur berformat teks/kategori menjadi representasi matematis.
- Terapkan algoritma encoding yang sesuai dengan sifat kategori tersebut (**Nominal vs Ordinal**).

D. Feature Scaling

- Terapkan penyetaraan skala agar seluruh rentang fitur numerik memiliki proporsi jarak yang setara, guna mencegah bias bobot pada algoritma ML klien di masa depan.

E. Scikit-Learn Pipeline Engineering (Wajib)

- Rangkai seluruh proses transformasi di atas menjadi satu alur arsitektur yang otomatis dan elegan.
- Requirements: Wajib menggunakan Class pembungkus arsitektur pipeline standar di industri (*Pipeline* dan *ColumnTransformer*).
- **Expected Output:** Data mentah klien dimasukkan di satu pintu, dan keluar sebagai sebuah objek array matriks 2D yang utuh, berskala seragam, dan *fully encoded*.

3. Deliverables

Dokumen handover kepada arsitek model ML diserahkan dalam bentuk Laporan Eksekutif (PDF), bukan file Jupyter Notebook (.ipynb). Laporan harus mencakup.

1. Data Profiling Summary: Daftar masalah/anomali yang Anda temukan pada data mentah klien.
2. Engineering Methodology: Teks penjelasan di balik pemilihan metode Anda pada Objektif B, C, dan D (misalnya: mengapa memilih scaler A atau encoder B).
3. *Architecture & Output:* Potongan kode (code snippet) disertai dengan tangkapan layar (screenshot) *array* output final yang siap masuk ke tahap *Machine Learning*.

Indikator Penilaian

Komponen Evaluasi	Kriteria Ekspektasi (KPI)	Bobot
Data Extraction & Cleansing	Berhasil memisahkan string gabungan, membersihkan teks pengganggu (Regex/String Manipulation), dan mengonversi tipe data dengan benar sebelum masuk <i>Pipeline</i> .	25 %
Feature Transformation Strategy	Ketepatan argumen dalam mengidentifikasi Nominal vs Ordinal. Pemilihan strategi imputasi, <i>encoding</i> , dan <i>scaling</i> sangat logis secara statistik.	25 %
Pipeline Architecture (Scikit-Learn)	Berhasil merangkai seluruh <i>transformer</i> ke dalam arsitektur Pipeline tanpa <i>error</i> , serta membuktikan <i>output</i> akhir menjadi <i>array/matrix</i> numerik yang utuh.	30 %
Reporting Quality (PDF)	Dokumen terstruktur dan profesional. Argumen teknis kuat, tidak bertele-tele, dan dokumentasi kode/output terbaca dengan sangat jelas.	20 %