

PROJECT TASK – WEEK 5

Divisi Python Machine Learning – Vinix7 (PT. Vinix Seven Aurum)

Latar Belakang

Minggu lalu, Anda telah membuktikan ketajaman logika Anda dengan membangun mesin *Gradient Descent* dari nol. Namun, dalam skala industri di Vinix7, kecepatan dan standarisasi adalah kunci.

Kita akan menggunakan kembali dataset **Student Performance** (10.000 siswa). Kali ini, tugas Anda bukan lagi menulis rumus matematika secara manual, melainkan merangkai arsitektur *end-to-end* menggunakan **Scikit-Learn** yang *robust* dan *scalable*.

Objektif

Anda diminta untuk membangun dua sistem prediksi (*Regresi & Klasifikasi*) dalam satu alur kerja yang otomatis.

1. Data Splitting Strategies

- Pisahkan data menjadi Training dan Testing set (80:20).
- Untuk target klasifikasi (**Status_Kelulusan**), pastikan proporsi siswa lulus dan tidak lulus tetap seimbang di kedua set data.

2. The All-in-One Pipeline

- Rangkai kembali **ColumnTransformer** dan gabungkan langsung dengan estimator *Scikit-Learn* menggunakan **Pipeline**.
- Regresi - Gunakan **LinearRegression** untuk memprediksi **Performance Index**.
- Klasifikasi - Gunakan **LogisticRegression** untuk memprediksi **Status_Kelulusan**.
- Requirement - Dilarang melakukan *scaling* atau *encoding* secara manual di luar objek **Pipeline**.

3. Model Evaluation

- **Regression Metrics** - Hitung **RMSE** (*Root Mean Squared Error*) dan **R-Squared**. Bandingkan hasilnya dengan skor Loss yang Anda dapatkan di Minggu 4.
- **Classification Metrics** - Jangan hanya terpaku pada **Accuracy**. Tampilkan *Precision*, *Recall*, dan *F1-Score*.
- Visualisasi - Tampilkan **Confusion Matrix** untuk melihat berapa banyak siswa yang salah diklasifikasikan.

4. Cross-Validation

- Gunakan `cross_val_score` untuk menguji stabilitas model Anda pada **5 fold** yang berbeda.

Deliverables

- Kelompok, Anggota, dan Link Google Colab.
- Pipeline Diagram: Lampirkan *screenshot* kode bagian **Pipeline** dan **ColumnTransformer**. Jelaskan secara singkat bagaimana **Pipeline** tersebut menangani data mentah hingga menjadi prediksi secara otomatis.
- Performa model **Regresi** - Tampilkan tabel perbandingan performa antara model **Custom Gradient Descent**. Kemudian interpretasikan apakah model **Scikit-Learn** lebih akurat? Apakah waktu **training-nya** lebih cepat? Berikan analisis singkat Anda.
- Performa model **Klasifikasi** – Tampilkan **Classification Report** (tabel/gambar tabel berisi *Accuracy*, *Precision*, *Recall*, dan *F1-Score*).
 - Visualisasikan *Confusion Matrix*.
 - Analisis bagian **False Negative** (Siswa yang diprediksi tidak lulus, padahal aslinya lulus). Apa risiko bisnisnya jika salah prediksi?
- Lampirkan hasil rata-rata skor dari **5-Fold Cross Validation** dan Jelaskan apakah skor antar-*fold* stabil atau melompat jauh.
- Engineering Reflection - Sebutkan 3 fitur atau fungsi di **Scikit-Learn** yang menurut kalian paling memudahkan pekerjaan *Machine Learning* dibandingkan melakukan koding manual seperti di Minggu 4.

Indikator Penilaian

Komponen Evaluasi	Kriteria Ekspektasi (KPI)	Bobot
Pipeline Integration	Berhasil menyatukan Preprocessing dan Model ke dalam satu objek Pipeline tanpa error.	30%
Evaluation Accuracy	Ketepatan penggunaan metrik (RMSE untuk regresi dan F1-Score untuk klasifikasi).	25%

Komponen Evaluasi	Kriteria Ekspektasi (KPI)	Bobot
Analysis Insight	Mampu memberikan alasan logis mengapa model Scikit-Learn mungkin lebih baik (atau buruk) dibanding model manual Minggu 4.	25%
Code Cleanliness	Penggunaan API Scikit-Learn secara efektif (tidak banyak kode yang berulang/redundant).	20%